WEB SCRAPING

PAULO CÉSAR TUYA

DiHiC Perú

ÍNDICE

- **Módulo 1: Introducción a Web Scraping**
  - Conociéndonos un poco
  - ¿Qué es Web Scraping?
  - Conociendo las API's
  - Conceptos relacionados a Web Scraping
  - Introducción al HTML
- Módulo 2: Herramientas para el Análisis de una Página Web
- Módulo 3: Web Scraping con Scrapy
- Módulo 4: Scraping en páginas dinámicas
- Módulo 5: Despliegue de un Spider

CONOCIÉNDONOS UN POCO

EL PROFESOR

- PUCP - Ingeniería Informática
- Data Science
- Predocente EE.GG.CC. y FCI
- Banco de Crédito del Perú
- Movistar Esports

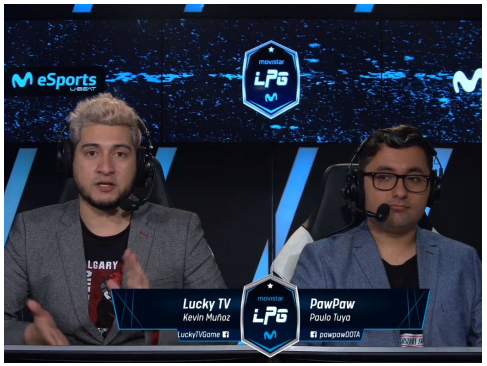

LOS ALUMNOS

- Nombre
- Background
  - Estudios
  - Experiencia o actualidad laboral
- Interés por el curso

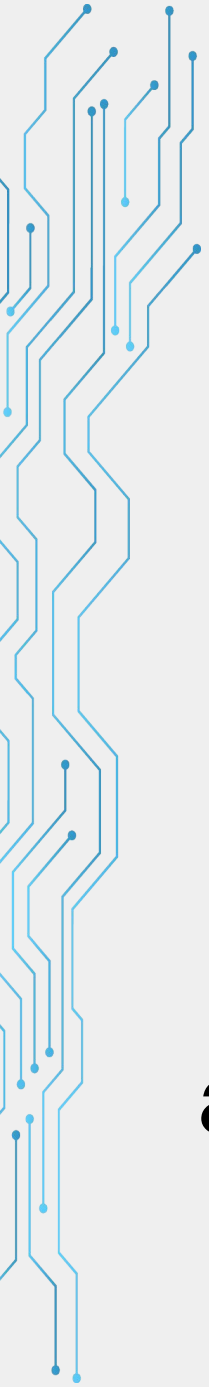

¿QUÉ ES WEB SCRAPING?

DMC
Perú

SCRAPING

- **Técnica** de extracción de datos
- Su peculiaridad es que opera sobre **contenido final**
- Técnica *ad hoc* y poco estable
- Ejemplos de uso:
  - Interfaz con un sistema no compatible
  - Creación de una API no oficial
  - **Extracción y minería de datos**

SCRAPING VS PARSING

WEB SCRAPING

WEB SCRAPING

- **Técnica** que **extrae** la información de un sitio web y la **transforma** en **data estructurada**
- Características:

Automatizado	vs	Manual
Gran escala		Página por página

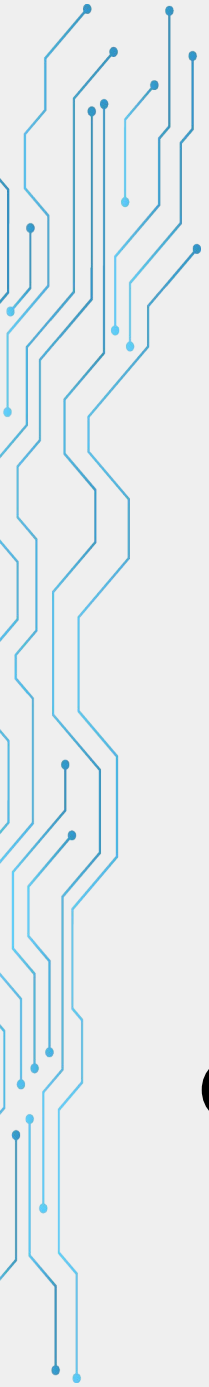

CONOCIENDO LAS APIS

DMC Perú

API

- Application Programming Interface
- Interfaz - Protocolo de comunicación entre un cliente y un servidor
- Permite interactuar con una aplicación y **realizar solicitudes de información**
- Muchos sitios web cuentan con una API abierta que ofrece data estructurada

API

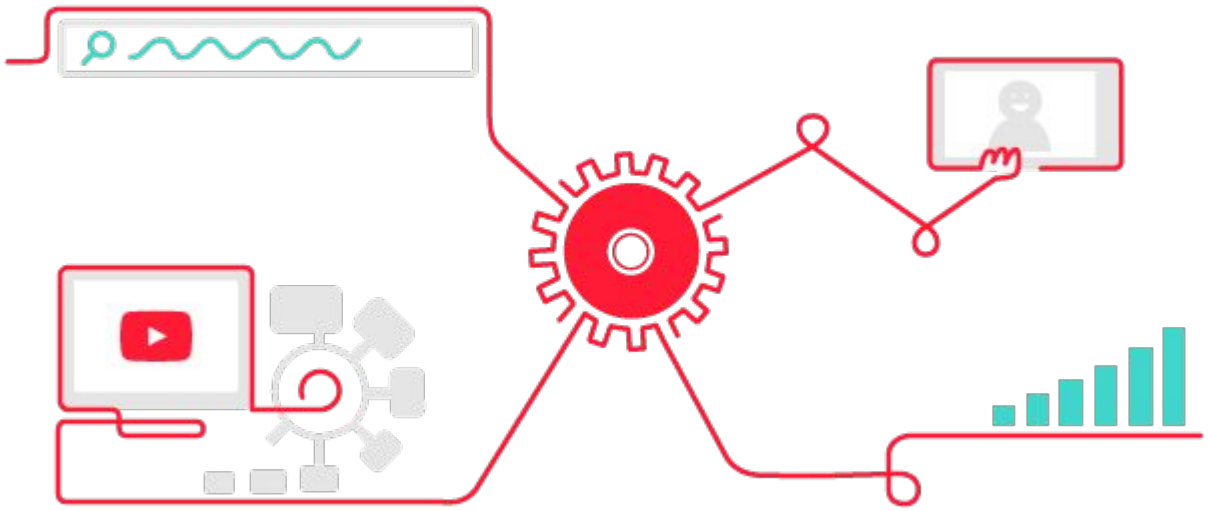

ALGUNAS APIS CONOCIDAS

- Facebook - https://developers.facebook.com/docs/graph-api/
- NASA - https://api.nasa.gov/
- PokémonGO - https://pokeapi.co/
- Instagram - https://www.instagram.com/developer/
- YouTube - https://developers.google.com/youtube/v3
- Spotify - https://developer.spotify.com/documentation/web-api/

¿WEB SCRAPING O USAR APIS?

- Utilizar API's ofrece **múltiples ventajas:**
  - Soporte oficial
  - Documentación de uso
  - Output estructurado
- Sin embargo, **no todas las páginas** ofrecen un API público

CONCEPTOS RELACIONADOS A WEB SCRAPING

TÓPICOS DE WEB SCRAPING

- Web Crawling
- Hipertexto
- HTTP
- Peticiones y Respuestas HTTP
- Markup
- HTML

WEB CRAWLING

- Técnica que consiste en navegar exhaustivamente **sitios web** para extraer **hipervínculos**
- Dichos hipervínculos son almacenados y utilizados para generar un **índice** del sitio web
- Técnica fundamental para los **motores de búsqueda**
- **No** almacena **información** que se encuentre dentro del sitio web

WEB CRAWLING VS WEB SCRAPING

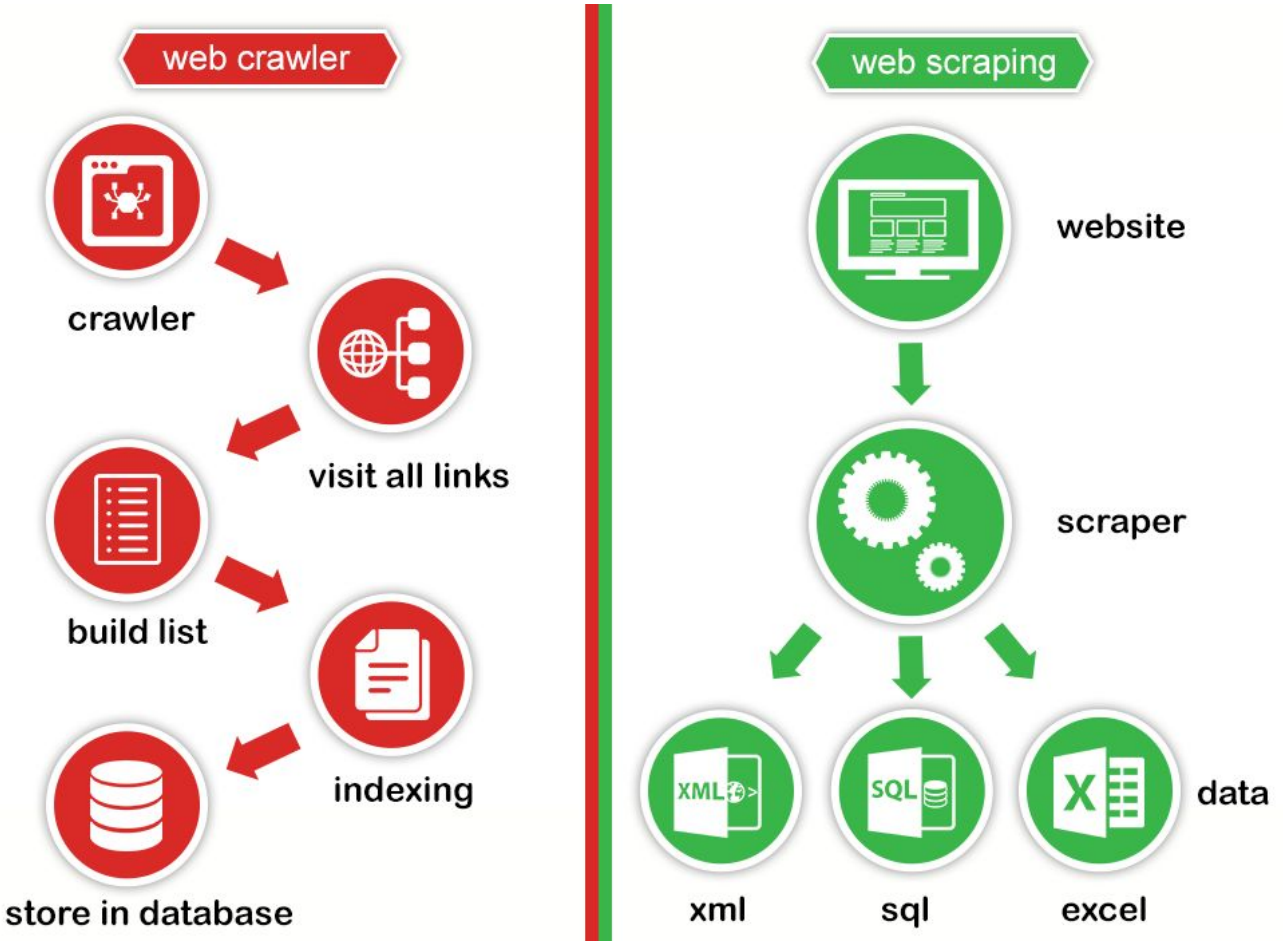

OTROS TOPICOS DE WEB SCRAPING

- Hipertexto
- HTTP
- HTTP REQUESTS
- MARKUP
- Notebooks de Python
-

HIPERTEXTO

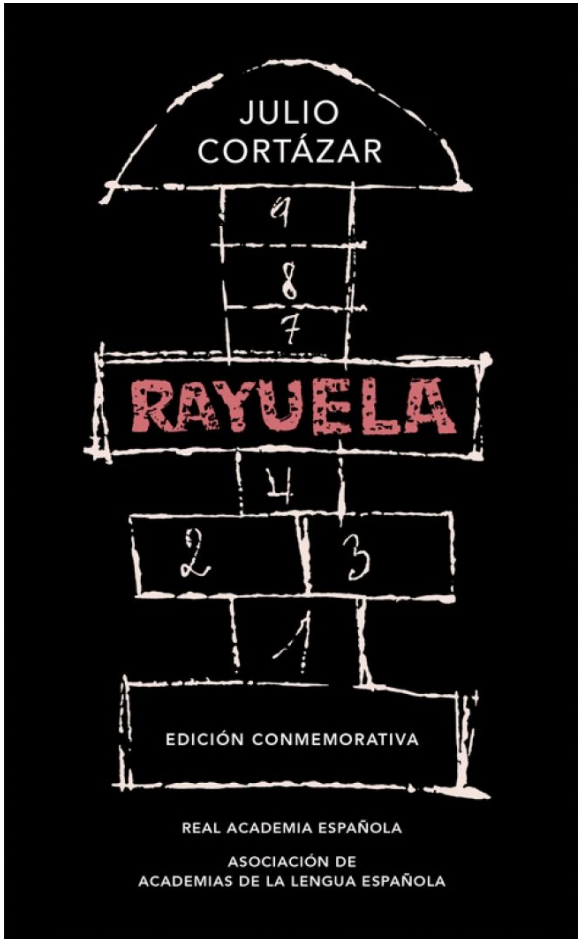

Perú

¿PENSAMIENTO HUMANO LINEAL O HIPERTEXTUAL?

HIPERTEXTO

- Estructura de texto no secuencial
- Pensamiento humano hipertextual
- Enlaces no secuenciales entre textos
- Implementación en Informática: **hipervínculos**

PROTOCOLO HTTP

- **H**ypertext **T**ransfer **P**rotocol
- Protocolo de transferencia que permite la comunicación en la WWW
- Esquema petición-respuesta:
  - Posee métodos para realizar peticiones
  - Envía respuestas con un código de respuesta adjunto

PROTOCOLO HTTP

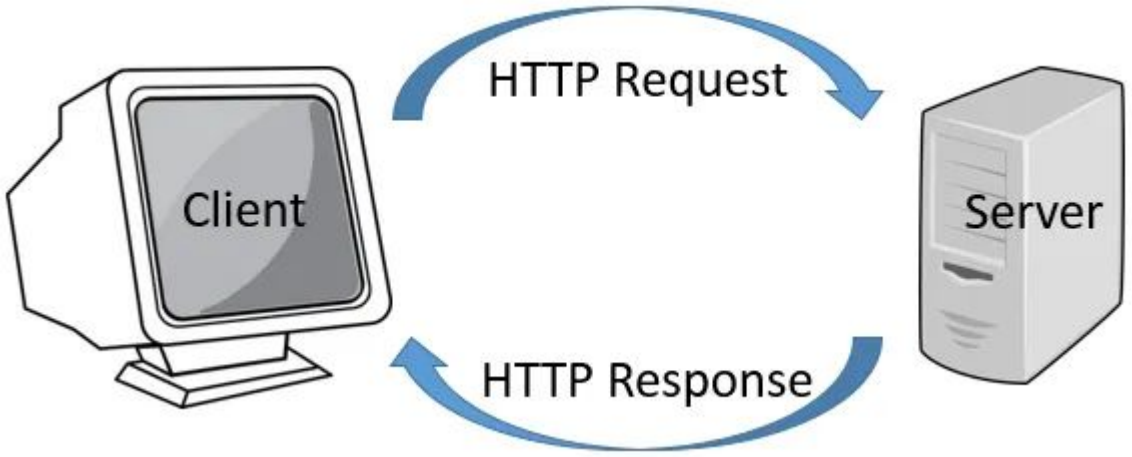

HISTORIA DEL PROTOCOLO HTTP

- 1991 - HTTP/0.9 - Solo soporta el comando GET
- 1996 - HTTP/1.0 - Permite métodos GET, HEAD, POST
- 1999 - HTTP/1.1 - Versión más usada. Pipelining
- 2000 - HTTP/1.2 - Extensión experimental de HTTP
- 2015 - HTTP/2.0 - Mejor empaquetado y transferencia
- 2019 - HTTP/2.4.39 - Última versión

MÉTODOS HTTP

- POST
- GET
- PUT
- PATCH
- DELETE
- ...

PETICIÓN HTTP

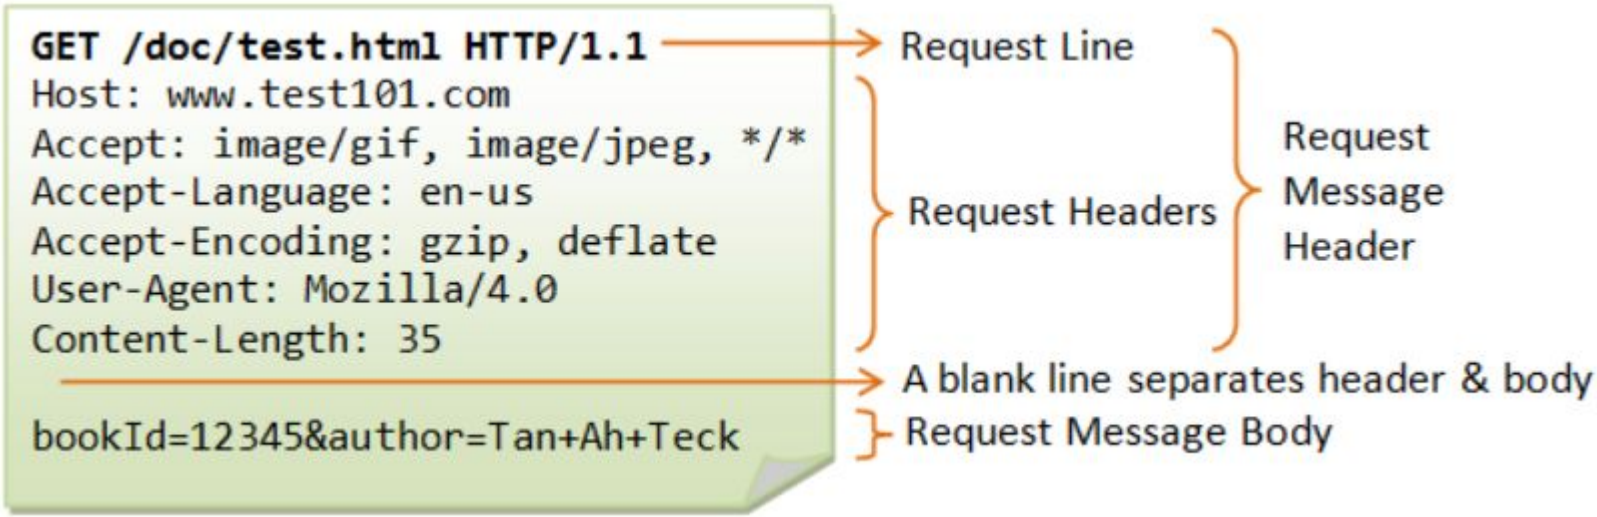

RESPUESTA HTTP

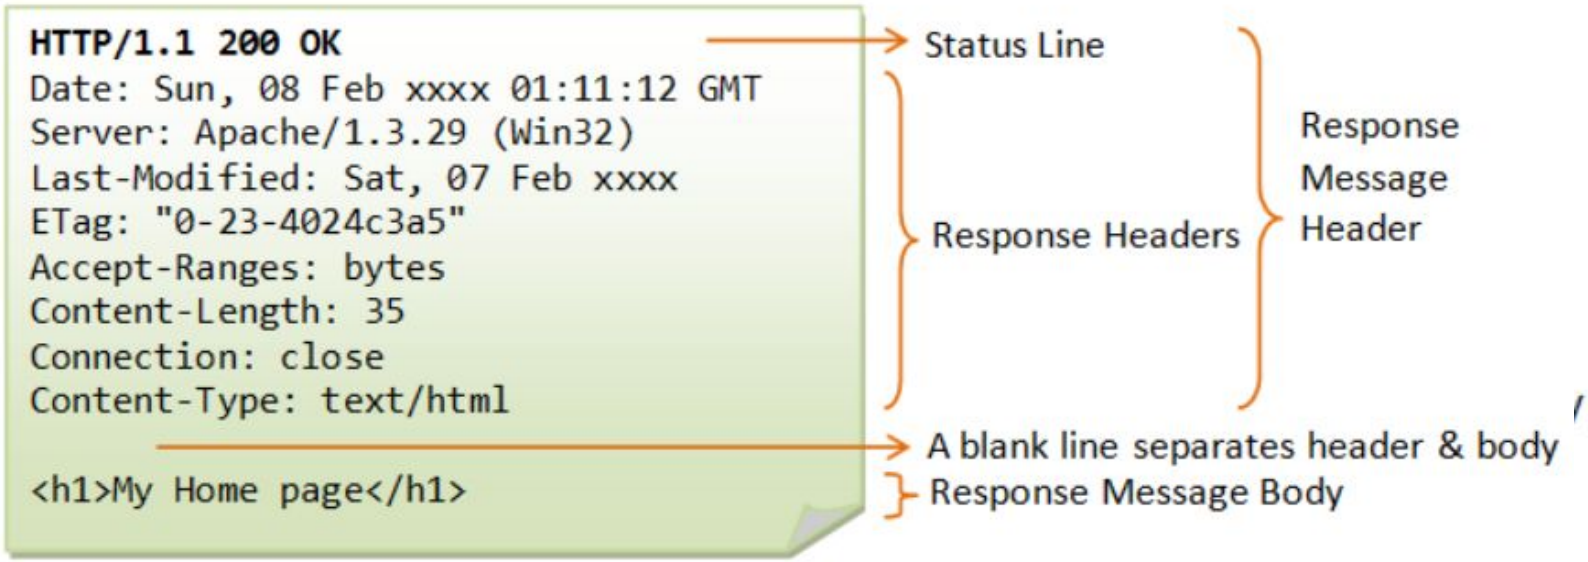

MARKUP

- **Sistema** de anotación de texto
- Distingue **anotaciones** de **contenido**
- Incorpora **etiquetas** para lograr esta diferenciación
- Ejemplos:
  - XML
  - XHTML
  - SGML
  - BBC
  - **HTML**

LENGUAJE MARKUP

```
<receta>
    <titulo>Arroz con Leche</titulo>
    <ingredientes>
        <ingrediente>Arroz</ingrediente>
        <ingrediente>Leche</ingrediente>
    </ingredientes>

    <preparacion>
        Sumerja el arroz crudo en la
        leche. Deje reposar por diez
        minutos. Sirva frio, con canela
        y clavo de olor al gusto
    </preparacion>
</receta>
```

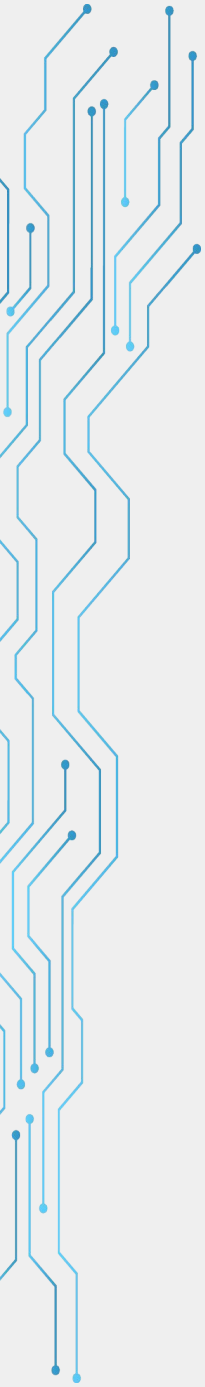

INTRODUCCIÓN A HTML

Perú

HTML

- **H**ypertext **M**arkup **L**anguage
- Lenguaje markup usado para la construcción de **páginas web**
- Separación texto-estructura-diseño
- HTML se centra en texto y estructura
- Estructura de **árbol**

Código HTML vs Output

```
1 <!-- Esto es un comentario -->
2 <h3>Bienvenidos al curso <b>Web Scraping en
  Python</b></h3>
3 <p><strong>Este curso les permitirá adquirir los
  conocimientos necesarios para usar las herramientas de
  Web Scraping disponibles en Python</strong></p>
4 <p>El profesor les guiará a lo largo de cada una de las
  sesiones con ejemplos, actividades, conceptualizaciones
  y explicaciones. Recuerden estar muy atentos a la clase
  y preguntar en caso tengan alguna duda.</p>
5 <img src="https://dmc.pe/uploads/logo2-dmc-2019.png"
  height="200" alt="dmc" />
```

Bienvenidos al curso **Web Scraping en Python**

Este curso les permitirá adquirir los conocimientos necesarios para usar las herramientas de Web Scraping disponibles en Python

El profesor les guiará a lo largo de cada una de las sesiones con ejemplos, actividades, conceptualizaciones y explicaciones. Recuerden estar muy atentos a la clase y preguntar en caso tengan alguna duda.

Estructura de árbol

```
<html>
  <head>
<title>Google</title>
<style>...</style>
  </head>
  <body>
    <div>...</div>
<center>...</center>
    <div>...</div>
  </body>
</html>
```

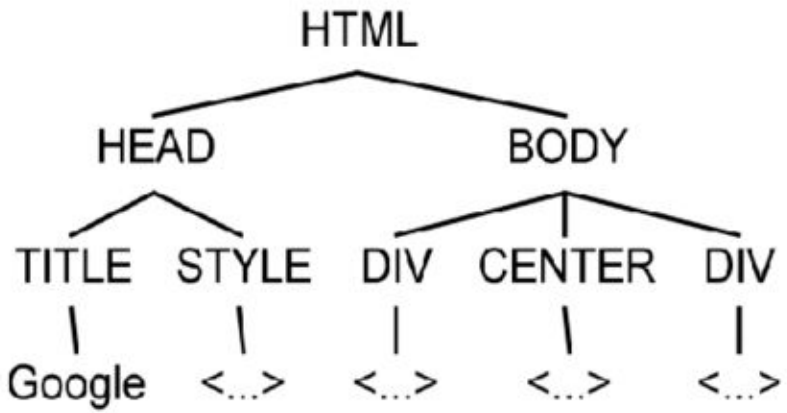

ETIQUETAS HTML

- Etiqueta que abarca un pedazo de **texto**
- Etiqueta HTML + texto interior = Elemento HTML
- En un árbol: nodo HTML = elemento HTML

ETIQUETAS HTML

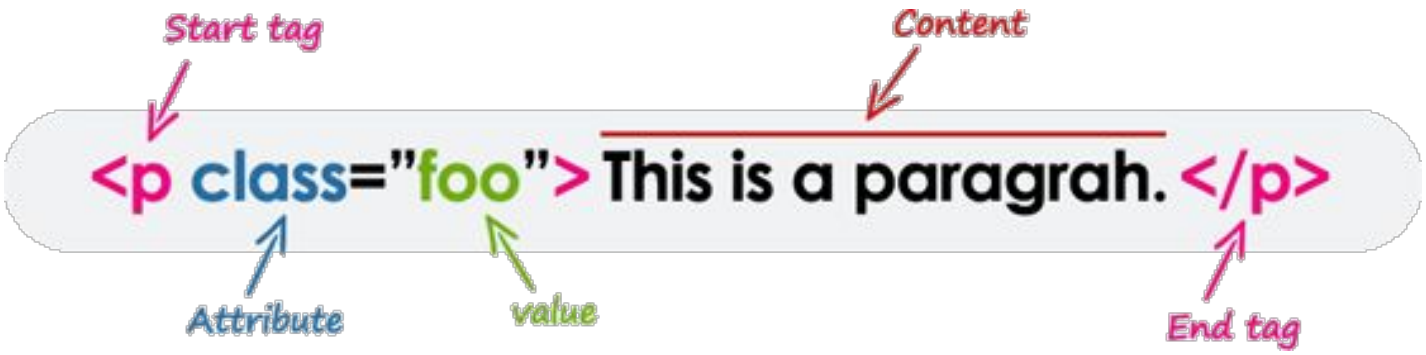

NUESTRO AMBIENTE DE TRABAJO

- Lenguaje de programación **Python**
- Entorno de desarrollo **Google Colab**

ACTIVIDAD MÓDULO 1

Perú

GRACIAS
POR SU ATENCIÓN

Perú